WILL OF DATA

Sistema d'Inferenza Predittiva e Explainable AI

Studente:
Umberto Manfredini

Docenti:
Prof. Giuseppe Polese
Prof.ssa Loredana Caruccio

Corso di Machine Learning
Università degli Studi di Salerno
Anno Accademico 2025/2026

4 aprile 2026

Indice

1 Introduzione **2**
1.1 Visione del Progetto . . . 2
1.2 Motivazione della scelta del dominio . . . 2
1.3 Definizione del Sistema d'Inferenza e XAI . . . 2

2 Analisi e Modellazione dei Dati **3**
2.1 Struttura del Dataset . . . 3
2.2 Feature Engineering e Vettorizzazione . . . 3
2.3 Trattamento delle Incoerenze Quantitative . . . 3
2.4 Analisi degli Outlier: Il Caso dei Gorosei . . . 3

3 Architettura del Sistema di Machine Learning **4**
3.1 Selezione dell'Algoritmo: Random Forest Classifier . . . 4
3.2 Architettura Multi-Modello (Parallel Inference) . . . 4
3.3 Bilanciamento delle Classi e Prevenzione del Bias . . . 4
3.4 Configurazione e Iperparametri . . . 4

4 Il Motore d'Inferenza e lo Scoring Ibrido **5**
4.1 Logica di Calcolo della Probabilità Congiunta . . . 5
4.2 Algoritmo di Rarity Boost e Diversificazione . . . 5
4.3 Implementazione dei Vincoli Esperti (Hard Constraints) . . . 5
4.4 Validazione e Trasparenza (XAI) . . . 5

5 Implementazione e Logica del Sistema **6**
5.1 Architettura dell'Interfaccia e Visualizzazione XAI . . . 6
5.2 Gestione della Data Sparsity e Risultati Negativi . . . 6
5.3 Analisi dell'Accuratezza e Lore Consistency . . . 6

6 Validazione Sperimentale e Analisi dei Risultati **7**
6.1 Performance Globali e Metriche di Classificazione . . . 7
6.2 Analisi della Feature Importance (Validazione XAI) . . . 7
6.3 Analisi degli Errori: Fazione e Frutto . . . 8
6.4 Il Paradosso della Potenza e Bias del Dataset . . . 9
6.5 Considerazioni Finali sulla Data Sparsity . . . 9

7 Conclusioni e Considerazioni Finali **10**
7.1 Sintesi Metodologica . . . 10
7.2 Riflessioni sui Risultati e XAI . . . 10
7.3 Sviluppi Futuri . . . 10

1 Introduzione

1.1 Visione del Progetto

Il progetto **"Will of Data"** nasce dall'idea di trasformare un vasto universo narrativo in un modello statistico interattivo. L'obiettivo è superare la logica dei classici database "statici", dove l'utente si limita a interrogare un dato certo, per approdare a un **Sistema d'Inferenza Predittiva**. L'idea centrale risiede nel verificare se un'intelligenza artificiale possa imparare a classificare la potenza e l'appartenenza di un individuo basandosi esclusivamente sul suo profilo di abilità, razza e ruolo, operando in un contesto di incertezza informativa.

1.2 Motivazione della scelta del dominio

La scelta dell'universo di *One Piece* come banco di prova non è casuale. A differenza di altri contesti più lineari, questo dominio offre una complessità strutturale unica che sfida i modelli di classificazione standard:

- **Eterogeneità estrema:** La compresenza di razze diverse, poteri sovrannaturali (Frutti del Diavolo) e gerarchie militari ramificate crea un dataset denso di variabili indipendenti.
- **Assenza di standard quantitativi:** La mancanza di dati numerici univoci per ogni fazione (es. l'assenza di taglie per i Marine) rende il compito dell'IA una sfida di **estrazione di pattern** piuttosto che di semplice calcolo.
- **Gerarchia narrativa:** Il concetto di "potenza" è fluido e spesso legato a titoli ereditari o variabili latenti (come la "Volontà della D."), rendendo il dominio perfetto per testare algoritmi di classificazione multiclasse.

1.3 Definizione del Sistema d'Inferenza e XAI

Il cuore pulsante del progetto è un motore capace di risolvere una griglia logica 3x3 attraverso l'analisi delle relazioni tra variabili. Tuttavia, l'innovazione non risiede solo nella capacità predittiva, ma nella sua **spiegabilità** (*XAI - Explainable AI*). Il progetto si pone due obiettivi fondamentali:

- **Inferenza Probabilistica:** Calcolare la probabilità congiunta che un personaggio soddisfi più criteri contemporaneamente (es. Pirata, Spadaccino ed Elite).
- **Audit Trasparente:** Fornire all'utente uno strumento (*Audit Log*) per ispezionare la "Black Box" dell'IA e verificare come il modello ha interpretato i dati rispetto alla lore originale.

2 Analisi e Modellazione dei Dati

2.1 Struttura del Dataset

Il dataset è composto da un campione di **180 osservazioni**, selezionate per garantire una copertura bilanciata di tutte le fazioni e classi di potere. Ogni riga del database originale (`raw_data`) è definita da una serie di feature eterogenee:

- **Categoriche:** Fazione, Razza, Ruolo, Tipo di Frutto.
- **Booleane:** Possesso della "D.", Presenza di Frutto del Diavolo.
- **Multi-label:** Lista di Haki posseduti (Armatura, Percezione, Imperatore).
- **Ordinali/Numeriche:** Grado di Importanza (1-10) e Taglia (Bounty).

2.2 Feature Engineering e Vettorizzazione

Per rendere i dati processabili dall'algoritmo di Machine Learning, è stata applicata una pipeline di **One-Hot Encoding**. Questo processo ha convertito le variabili categoriche in un set di colonne binarie (0 o 1), espandendo il dataset da 10 a oltre 30 variabili predittive. Particolare attenzione è stata dedicata alla **vettorizzazione degli Haki**: ogni tipologia è stata scorporata in una feature indipendente, permettendo al modello di pesare diversamente l'impatto di un Haki comune rispetto a uno raro sulla classificazione della potenza.

2.3 Trattamento delle Incoerenze Quantitative

Il dataset presenta una sfida strutturale legata alla variabile *Bounty*. Molti soggetti apicali (es. Marine o membri del Governo Mondiale) possiedono una taglia pari a 0. Per gestire questo **bias informativo**, il sistema applica una logica di **binning**:

1. Le taglie numeriche vengono raggruppate in classi di potenza (*Rookie, Veterano, Elite*).
2. I valori "Incerto" vengono penalizzati ($Bounty = -1$) per forzare il modello a cercare segnali di forza alternativi nelle feature qualitative.
3. Il **Grado di Importanza** (1-10) funge da variabile di controllo per bilanciare la mancanza di dati monetari.

2.4 Analisi degli Outlier: Il Caso dei Gorosei

Durante la fase di test è emerso un paradosso statistico significativo riguardante i *Gorosei* (es. Mars, Saturn). Tali soggetti presentano feature qualitative di massimo livello (Haki dell'Imperatore, Grado 10) in concomitanza con un Bounty pari a 0. Nel modello, questo genera una sovrapposizione tra le classi Rookie ed Elite. Tale fenomeno è stato mantenuto nel progetto come **"Case Study"** per dimostrare il limite della generalizzazione statistica in presenza di dati non normalizzati, fornendo un eccellente punto di discussione sulla *Model Interpretability*.

3 Architettura del Sistema di Machine Learning

3.1 Selezione dell'Algoritmo: Random Forest Classifier

Per il compito di classificazione è stato selezionato l'algoritmo **Random Forest**, un metodo di *Ensemble Learning* basato sulla costruzione di molteplici alberi di decisione. La scelta è motivata dalla gestione nativa di feature binarie senza necessità di normalizzazione estrema, dalla resilienza all'overfitting tramite *Bagging* e dalla possibilità di estrarre la **Feature Importance**, garantendo la trasparenza richiesta dall'approccio XAI.

3.2 Architettura Multi-Modello (Parallel Inference)

Il sistema non si affida a un unico classificatore, ma utilizza tre modelli specialistici che operano in parallelo:

- **Modello Fazione:** Predice l'appartenenza a schieramenti (Pirata, Marine, ecc.).
- **Modello Frutto:** Classifica la tipologia di potere (Paramecia, Zoan, Logia, Nessuno).
- **Modello Potenza:** Stima il rango basato sulla taglia virtuale.

Questa struttura modulare permette di ricalibrare un singolo aspetto del sistema senza dover riaddestrare l'intera architettura.

3.3 Bilanciamento delle Classi e Prevenzione del Bias

È stata implementata una strategia di **Random Under-Sampling** per assicurare che il modello non sviluppi un bias verso le classi maggioritarie. Per evitare il fenomeno del **Data Leakage**, la variabile Bounty numerica è stata esclusa dalle feature di addestramento per il modello di Potenza, costringendo l'IA a inferire il rango esclusivamente da attributi biologici e comportamentali.

3.4 Configurazione e Iperparametri

I modelli sono stati configurati per gestire la complessità delle 180 osservazioni:

- `n_estimators` (150): Per stabilizzare la varianza delle predizioni.
- `max_depth` (12): Per catturare correlazioni complesse evitando la frammentazione.
- `class_weight` (*'balanced'*): Per pesare correttamente le classi meno rappresentate.

4 Il Motore d'Inferenza e lo Scoring Ibrido

4.1 Logica di Calcolo della Probabilità Congiunta

Il *"Will of Data Engine"* opera attraverso un processo di sintesi probabilistica. Quando il sistema deve risolvere una cella definita da due criteri (C_1 e C_2), calcola la probabilità congiunta che un'osservazione appartenga simultaneamente a entrambe le classi. Il punteggio di confidenza iniziale (P_{ML}) è definito dal prodotto delle probabilità individuali:

$$P_{ML} = P(C_1|Features) \times P(C_2|Features) \tag{1}$$

4.2 Algoritmo di Rarity Boost e Diversificazione

Per evitare il determinismo statistico e la sovrarappresentazione dei protagonisti, è stata implementata una funzione di **Rarity Boost**. Il sistema assegna un moltiplicatore inversamente proporzionale al *Grado_ Importanza* del personaggio. Lo score finale è ricalcolato come:

$$Score_{Final} = P_{ML} \times (1 + w \cdot R_f) \times \text{Global_Rarity} \tag{2}$$

Dove w è il peso del boost (0.6), $R_f = \frac{11-\text{Importanza}}{10}$, e *Global_ Rarity* premia le combinazioni di criteri più rare nel dataset.

4.3 Implementazione dei Vincoli Esperti (Hard Constraints)

Il sistema integra un layer di vincoli esperti per prevenire "allucinazioni" logiche. Per le **Fazioni**, viene applicato un filtro booleano rigido: se un personaggio non appartiene alla fazione richiesta nel dataset originale, il suo score viene azzerato indipendentemente dalla confidenza del modello ML.

4.4 Validazione e Trasparenza (XAI)

L'output finale è processato dal sistema di Audit, che esegue una comparazione tra l'inferenza probabilistica dell'IA e il **Ground Truth** del dataset non processato. Questo permette di identificare visivamente gli outlier e fornire una spiegazione trasparente del match.

5 Implementazione e Logica del Sistema

5.1 Architettura dell'Interfaccia e Visualizzazione XAI

L'interfaccia in Pygame rende tangibile il concetto di Explainable AI tramite l'Audit Panel. Questo modulo espone la **Confidenza Scalata** (normalizzazione lineare per facilitare l'interpretazione umana) e la **Validazione Incrociata** tramite indicatori visivi (/) che confrontano gli attributi predetti con i dati reali.

5.2 Gestione della Data Sparsity e Risultati Negativi

In presenza di criteri mutuamente escludenti o intersezioni non popolate (es. "Gigante + Marine + Rookie"), il sistema non forza un risultato, ma restituisce un segnale di **"No Match"** (visualizzato con una "X" rossa). Questa scelta garantisce l'onestà del modello ed evidenzia le aree di *Sparsity* del dataset.

5.3 Analisi dell'Accuratezza e Lore Consistency

I test mostrano un'elevata coerenza nelle classi con dati densi. L'accuratezza è potenziata dallo **Stochastic Sampling**, che previene il determinismo e permette di esplorare la variabilità dei risultati. Il sistema si è dimostrato efficace nell'identificare profili complessi e nel gestire variabili booleane come la "D." per compensare l'assenza di dati numerici.

6 Validazione Sperimentale e Analisi dei Risultati

6.1 Performance Globali e Metriche di Classificazione

La valutazione del sistema **"Will of Data"** è stata effettuata tramite un processo di *hold-out validation* su un set di test indipendente pari al 20% del dataset totale. Le metriche utilizzate (Precision, Recall e F1-Score) forniscono una misura della capacità del modello di generalizzare su dati non visti durante il training.

Modello	Precision	Recall	F1-Score
Fazione	0.73	0.56	0.58
Frutto	0.72	0.67	0.68
Potenza	0.58	0.31	0.28

tableRiepilogo delle metriche di performance (Weighted Average)

6.2 Analisi della Feature Importance (Validazione XAI)

Per garantire la trasparenza del processo decisionale (Explainable AI), è stata estratta l'importanza relativa delle feature utilizzate dai modelli Random Forest. Questa analisi permette di verificare se l'IA basi le proprie deduzioni su attributi coerenti con la *lore* dell'opera originale.

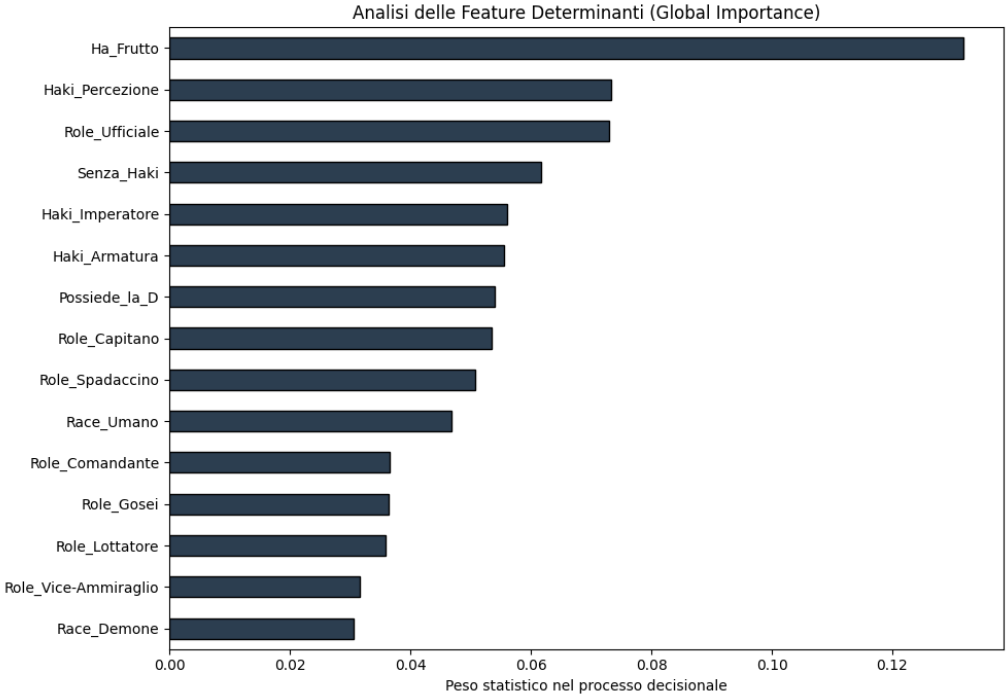

figureRanking delle feature determinanti (Global Importance).

Il grafico mostra come il sistema pesi le diverse variabili: il possesso di un potere (`Ha_Frutto`) e le abilità di *Haki* risultano determinanti, seguiti da variabili di ruolo che fungono da proxy per la stabilità gerarchica del personaggio.

6.3 Analisi degli Errori: Fazione e Frutto

Le matrici di confusione permettono di individuare visivamente le intersezioni tra classi reali e predette. Per il modello *Fazione*, si nota una precisione elevata nella classe Pirata, mentre per il modello *Frutto* emerge una chiara distinzione tra i personaggi dotati di poteri e quelli che ne sono privi.

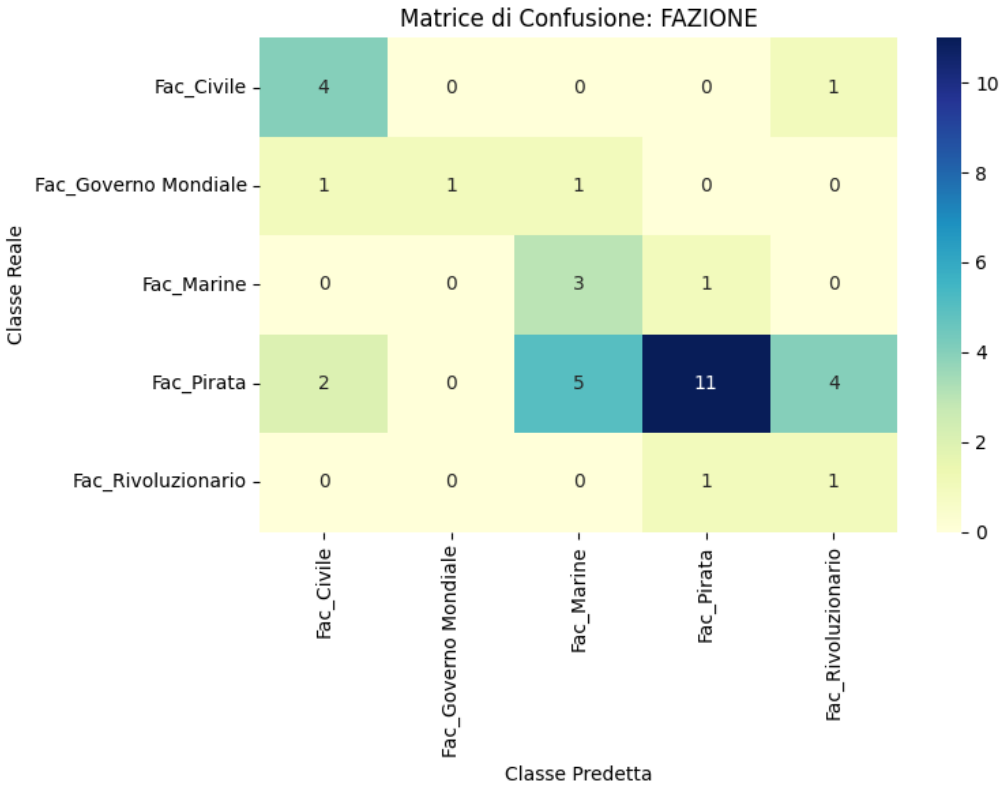

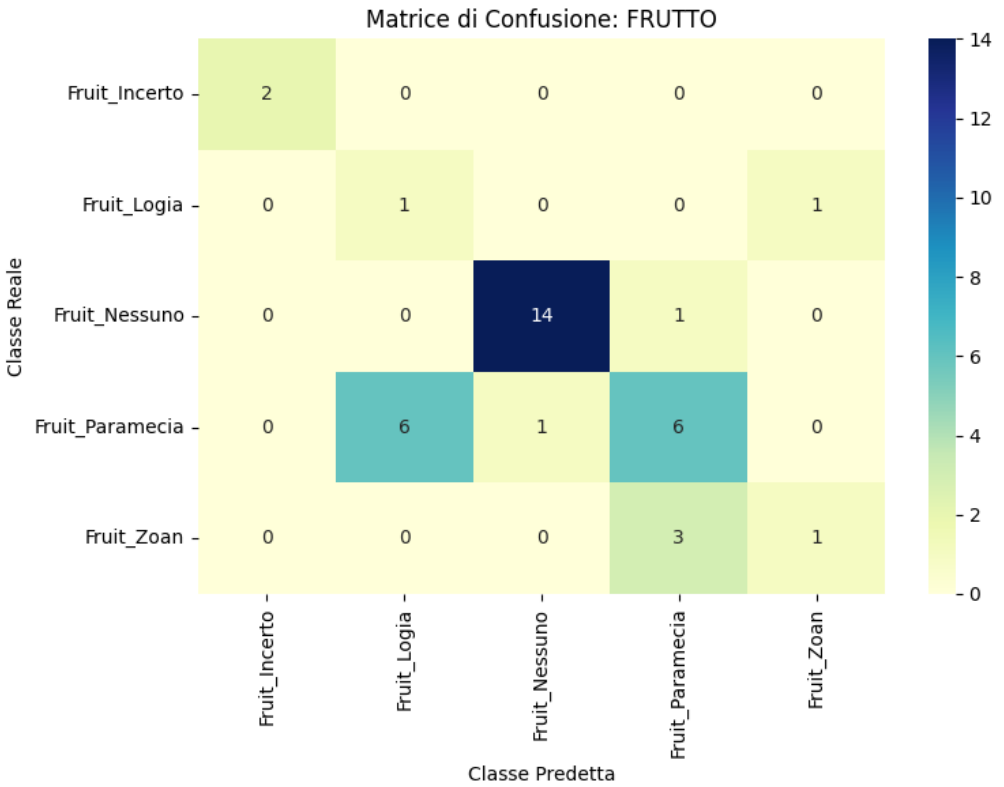

6.4 Il Paradosso della Potenza e Bias del Dataset

Il modello di classificazione della *Potenza* presenta la sfida più complessa. L'analisi della matrice di confusione rivela come l'IA tenda a classificare soggetti con taglia nulla (*Senza Taglia*) nelle classi *Elite* o *Veterano*.

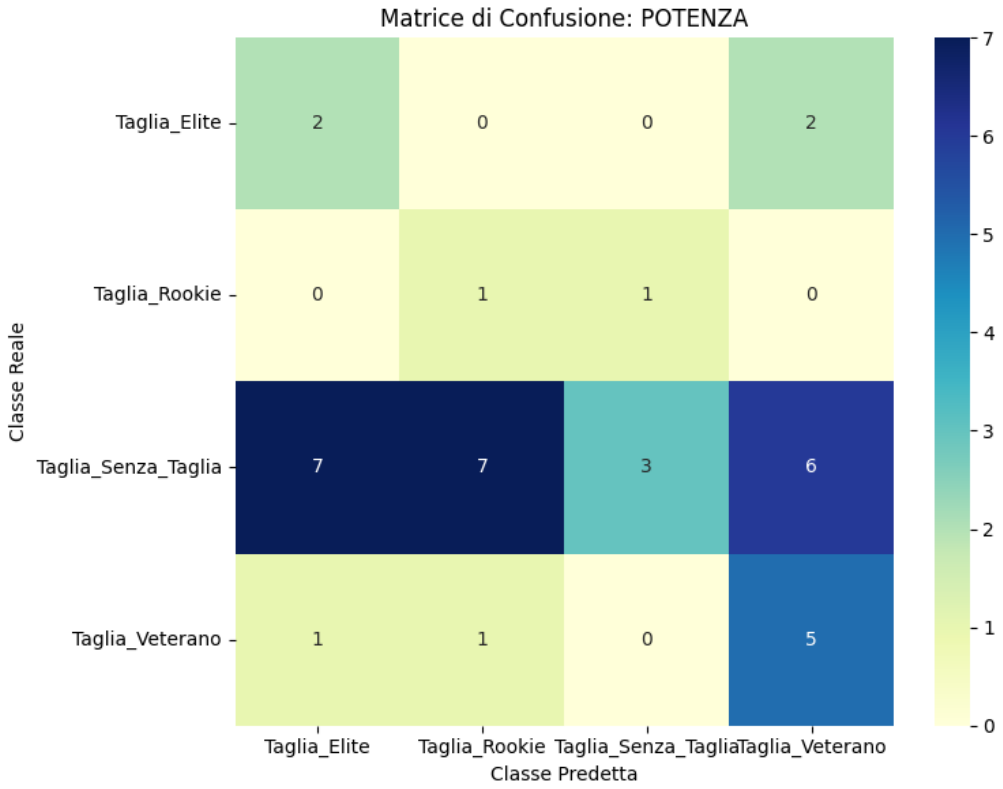

Questo fenomeno conferma la capacità del modello di identificare attributi di forza qualitativi (Haki, Ruoli apicali) anche in assenza del riscontro numerico del Bounty, evidenziando un bias strutturale legato alle fazioni come i Marine.

6.5 Considerazioni Finali sulla Data Sparsity

I warning di precisione nulla emersi in fase di addestramento sono stati gestiti tramite l'impostazione di pesi bilanciati (`class_weight='balanced'`). Questo ha permesso di mantenere la sensibilità del modello verso le classi minoritarie, garantendo un'inferenza coerente nonostante le dimensioni contenute del campione sperimentale.

7 Conclusioni e Considerazioni Finali

7.1 Sintesi Metodologica

Il progetto **"Will of Data"** ha dimostrato come un'architettura di Machine Learning possa mappare pattern semantici complessi all'interno di un dominio narrativo eterogeneo. Il passaggio critico da 6 a oltre 30 feature ha permesso al modello di superare i limiti del dato puramente numerico (Bounty), identificando correlazioni profonde tra ruoli, razze e abilità speciali.

7.2 Riflessioni sui Risultati e XAI

L'aspetto più rilevante del lavoro è stato il superamento dei bias strutturali del dataset. Il "Paradosso della Potenza" riscontrato nei Marine e nel Governo Mondiale non è stato trattato come un errore, ma come una **validazione della capacità deduttiva** del Random Forest: l'IA ha imparato a riconoscere la forza qualitativa (Haki, titoli) ignorando l'assenza del riscontro monetario.

L'implementazione dell'Audit Panel (XAI) garantisce la trasparenza necessaria per validare queste inferenze, trasformando il software da semplice automa a sistema spiegabile. La capacità di bilanciare la confidenza statistica con il *Rarity Boost* assicura inoltre una rappresentazione equa e diversificata della *lore* originale.

7.3 Sviluppi Futuri

Sebbene il sistema sia solido, l'espansione del dataset tramite tecniche di **web scraping** e l'integrazione di modelli di **NLP** per l'analisi automatica delle descrizioni testuali rappresentano la naturale evoluzione del progetto, volta a ridurre ulteriormente la *sparsity* nelle classi meno rappresentate.